

# Theory task ML

Бунин Кирилл Андреевич, Б05-203

Dec 10, 2024

## Bias-Variance decomposition

### 1 Теория

Допустим, у нас есть некоторая выборка, на которой линейные методы работают лучше решающих деревьев с точки зрения ошибки на контроле. Почему это так? Чем можно объяснить превосходство определённого метода обучения? Оказывается, ошибка любой модели складывается из трёх факторов: сложности самой выборки, схожести модели с истинной зависимостью ответов от объектов в выборке, и богатства семейства, из которого выбирается конкретная модель. Между этими факторами существует некоторый баланс, и уменьшение одного из них приводит к увеличению другого. Такое разложение ошибки носит название разложения на смещение и разброс, и его формальным выводом мы сейчас займёмся.

Пусть задана выборка  $X = (x_i, y_i)_{i=1}^n$  с вещественными ответами  $y_i \in \mathbb{R}$  (рассматриваем задачу регрессии). Будем считать, что на пространстве всех объектов и ответов  $X \times Y$  существует распределение  $p(x, y)$ , из которого сгенерирована выборка  $X$  и ответы на ней. Рассмотрим квадратичную функцию потерь

$$L(y, a) = (y - a(x))^2$$

и соответствующий ей среднеквадратичный риск

$$R(a) = \mathbb{E}_{x,y} [(y - a(x))^2] = \int_X \int_Y p(x, y) (y - a(x))^2 dx dy.$$

Данный функционал усредняет ошибку модели в каждой точке пространства  $x$  и для каждого возможного ответа  $y$ , причём вклад пары  $(x, y)$ , по сути, пропорционален вероятности получить её в выборке  $p(x, y)$ . Разумеется, на практике мы не можем вычислить данный функционал, поскольку распределение  $p(x, y)$  неизвестно. Тем не менее, в теории он позволяет измерить качество модели на всех возможных объектах, а не только на наблюдаемой выборке.

### 2 Задание

Покажите, что минимум среднеквадратичного риска достигается на функции, возвращающей условное математическое ожидание ответа при фиксированном объекте.

$$a_*(x) = \mathbb{E}[y \mid x] = \int_Y y p(y \mid x) dy = \arg \min_a R(a).$$

Иными словами покажите, что мы должны провести «взвешенное голосование» по всем возможным ответам, при этом веса ответа равны апостериорной вероятности.

### 3 Решение

Преобразуем функцию потерь:

$$\begin{aligned} L(y, a(x)) &= (y - a(x))^2 = (y - \mathbb{E}(y | x) + \mathbb{E}(y | x) - a(x))^2 = \\ &= (y - \mathbb{E}(y | x))^2 + 2(y - \mathbb{E}(y | x))(\mathbb{E}(y | x) - a(x)) + (\mathbb{E}(y | x) - a(x))^2. \end{aligned}$$

Подставляя её в функционал среднеквадратичного риска, получаем:

$$\begin{aligned} R(a) &= \mathbb{E}_{x,y}[L(y, a(x))] = \\ &= \mathbb{E}_{x,y}[(y - \mathbb{E}(y | x))^2] + \mathbb{E}_{x,y}[(\mathbb{E}(y | x) - a(x))^2] + 2\mathbb{E}_{x,y}[(y - \mathbb{E}(y | x))(\mathbb{E}(y | x) - a(x))]. \end{aligned}$$

Разберёмся сначала с последним слагаемым. Перейдём от матожидания  $\mathbb{E}_{x,y}[f(x, y)]$  к цепочке матожиданий:

$$\mathbb{E}_x \mathbb{E}_y[f(x, y) | x] = \int_X \left( \int_Y f(x, y) p(y | x) dy \right) p(x) dx$$

и заметим, что величина  $(\mathbb{E}(y | x) - a(x))$  не зависит от  $y$ , и поэтому её можно вынести за матожидание по  $y$ :

$$\begin{aligned} \mathbb{E}_x \mathbb{E}_y[(y - \mathbb{E}(y | x))(\mathbb{E}(y | x) - a(x)) | x] &= \\ &= \mathbb{E}_x((\mathbb{E}(y | x) - a(x)) \mathbb{E}_y[(y - \mathbb{E}(y | x)) | x]) = \\ &= \mathbb{E}_x((\mathbb{E}(y | x) - a(x))(\mathbb{E}_y[y | x] - \mathbb{E}_y \mathbb{E}(y | x))) = \\ &= 0. \end{aligned}$$

Получаем, что функционал среднеквадратичного риска имеет вид:

$$R(a) = \mathbb{E}_{x,y}(y - \mathbb{E}(y | x))^2 + \mathbb{E}_{x,y}((\mathbb{E}(y | x) - a(x))^2).$$

От алгоритма  $a(x)$  зависит только второе слагаемое, и оно достигает своего минимума, если  $a(x) = \mathbb{E}(y | x)$ . Таким образом, оптимальная модель регрессии для квадратичной функции потерь имеет вид:

$$a_*(x) = \mathbb{E}(y | x) = \int_Y y p(y | x) dy.$$

Что и требовалось показать.